Rapport de Projet : Mise en Œuvre d'un Data Mart

Intégration Pentaho Data Integration 11 et MySQL

Emna Ayachi GLSI-2A
Université de Carthage

Avril 2026

Table des matières

1 Introduction Générale **2**
1.1 Contexte du Projet 2
1.2 Objectifs Techniques 2
1.3 Technologies Utilisées 2

2 Préparation de l'Environnement **3**
2.1 Installation de MySQL Workbench 3
2.2 Conception du Schéma Data Mart 3
2.2.1 Modélisation en Étoile 3
2.2.2 Création Technique 4

3 Installation et Configuration Pentaho 11 **5**
3.1 Téléchargement et Installation 5
3.2 Configuration JDBC MySQL 5
3.3 Connexions Bases de Données 5

4 Processus ETL Détaillé **7**
4.1 Transformation Générale 7
4.2 Dimension Produits 7
4.2.1 Extraction 7
4.2.2 Chargement 7
4.3 Dimension Clients 8
4.4 Dimension Temps 9
4.4.1 Extraction et Transformation 9
4.5 Faits Ventes (Agrégation) 9

5 Vérification et Validation **10**
5.1 Contrôle des Données 10
5.2 Exemples de Données Chargées 10
5.3 Tests d'Intégrité 10

6 Conclusion et Perspectives **11**
6.1 Bilan du Projet 11

Chapitre 1

Introduction Générale

1.1 Contexte du Projet

Ce rapport documente la mise en œuvre complète d'un **Data Mart** dédié à l'analyse des ventes, réalisé dans le cadre d'un projet universitaire à l'Institut Supérieur des Technologies de l'Information et de la Communication (ISTIC), Université de Carthage.

Le projet consiste à partir d'une base de données opérationnelle `Prod` pour construire un entrepôt de données analytiques `ventesDM` permettant d'étudier l'évolution des quantités et montants des ventes selon les dimensions **Temps**, **Clients** et **Produits**. L'objectif principal est de supporter des analyses OLAP par jour et par mois, avec regroupement des produits par catégories et des clients par pays.

1.2 Objectifs Techniques

- Concevoir un schéma en étoile optimisé pour l'analyse multidimensionnelle
- Implémenter un processus ETL complet avec **Pentaho Data Integration 11**
- Intégrer les données sources MySQL vers le Data Mart cible
- Vérifier l'intégrité et la qualité des données chargées

1.3 Technologies Utilisées

- **MySQL Workbench 8.3** pour la conception et la vérification
- **Pentaho Data Integration 11 Community Edition** (Spoon)
- **MySQL Server 8.3** pour les bases opérationnelle et Data Mart
- **JDBC Driver MySQL 9.6.0**

Chapitre 2

Préparation de l'Environnement

2.1 Installation de MySQL Workbench

1. Démarrage de `MySQL Workbench`
2. Import du script `ProductionDumpExemple.sql`
3. Exécution complète via `Ctrl+Shift+Enter`
4. Vérification du schéma `Prod` créé avec succès

Le schéma opérationnel contient les tables essentielles : `produits`, `categories`, `clients`, `commandes`, `DetailsCmd`.

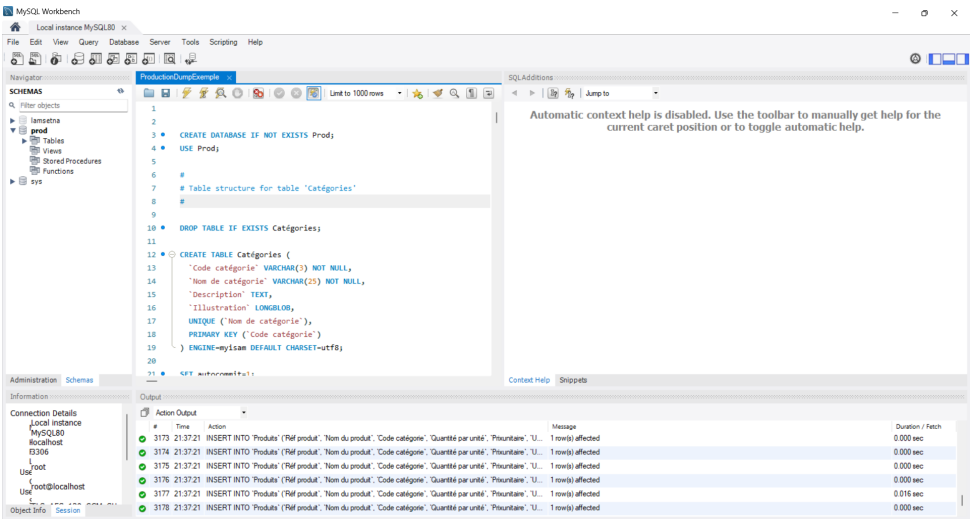

FIGURE 2.1 – Shéma Operationnel

2.2 Conception du Schéma Data Mart

2.2.1 Modélisation en Étoile

Le Data Mart `ventesDM` adopte un schéma en étoile classique :

Table	Champs	Rôle
`DimTemps`	idJours (DATE, PK), Mois (INT)	Dimension temporelle
`DimProduits`	idProd (INT, PK), NomProd, CatProd	Dimension produits
`DimClients`	idCl (VARCHAR(5), PK), NomCl, PaysCl	Dimension clients
`FactVentes`	Quantite (INT), Montant (DOUBLE), FKs	Faits de ventes

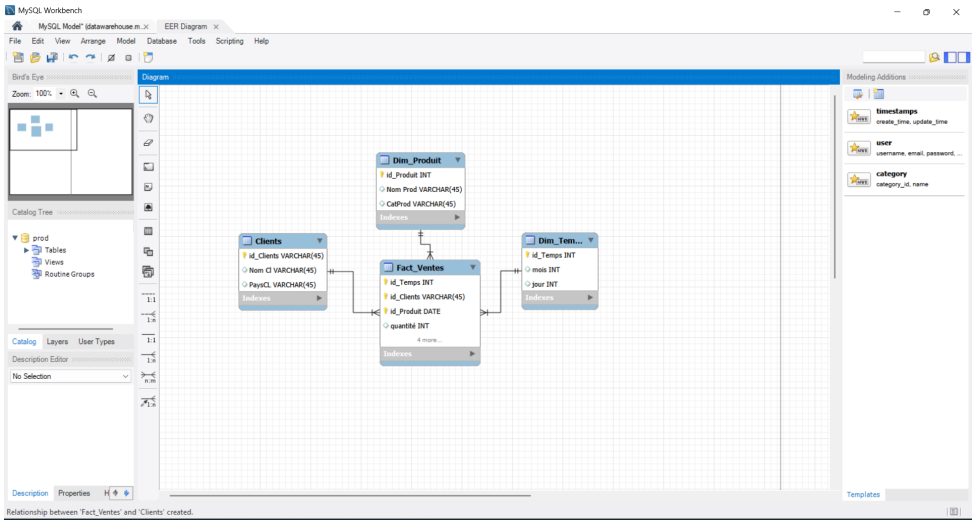

FIGURE 2.2 – Modèle en étoile

2.2.2 Création Technique

1. `File` > `New Model` dans MySQL Workbench
2. Définition des tables et relations FK
3. Génération : `Database` > `Forward Engineer`
4. Exécution du script dump généré

Chapitre 3

Installation et Configuration Pentaho 11

3.1 Téléchargement et Installation

1. Téléchargement de `PDI-CE-11.x.x` depuis SourceForge
2. Décompression dans `C:\Pentaho\data-integration`
3. Lancement via `spoon.bat` (Administrateur requis)

3.2 Configuration JDBC MySQL

1. Téléchargement `mysql-connector-j-9.6.0.jar`
2. Copie dans `lib/`
3. Redémarrage de Spoon
4. Test des connexions réussies

3.3 Connexions Bases de Données

— `connectprod` : `localhost:3306/prod/root`
— `connectdatamart` : `localhost:3306/ventesDM/root`

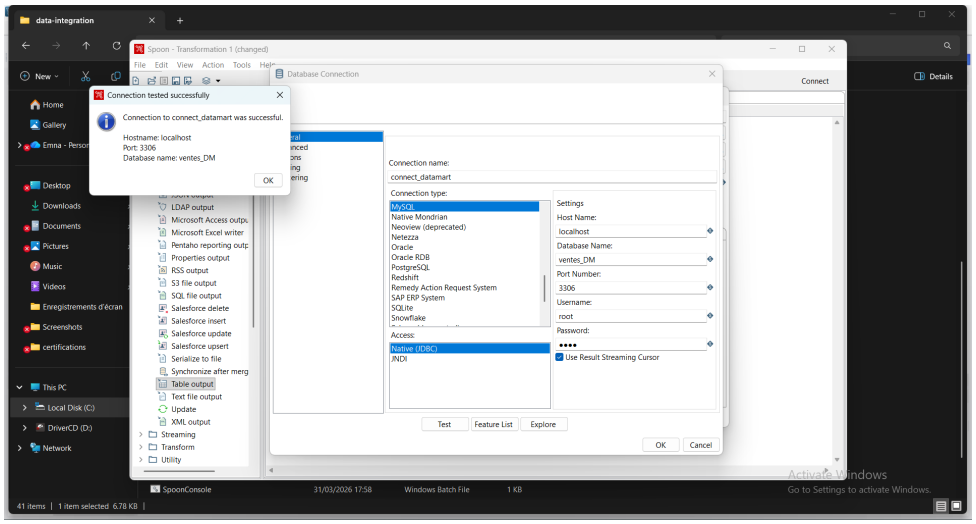

FIGURE 3.1 – Succès du connexion

Chapitre 4

Processus ETL Détaillé

4.1 Transformation Générale

Une transformation unique agrège les 4 flux ETL :

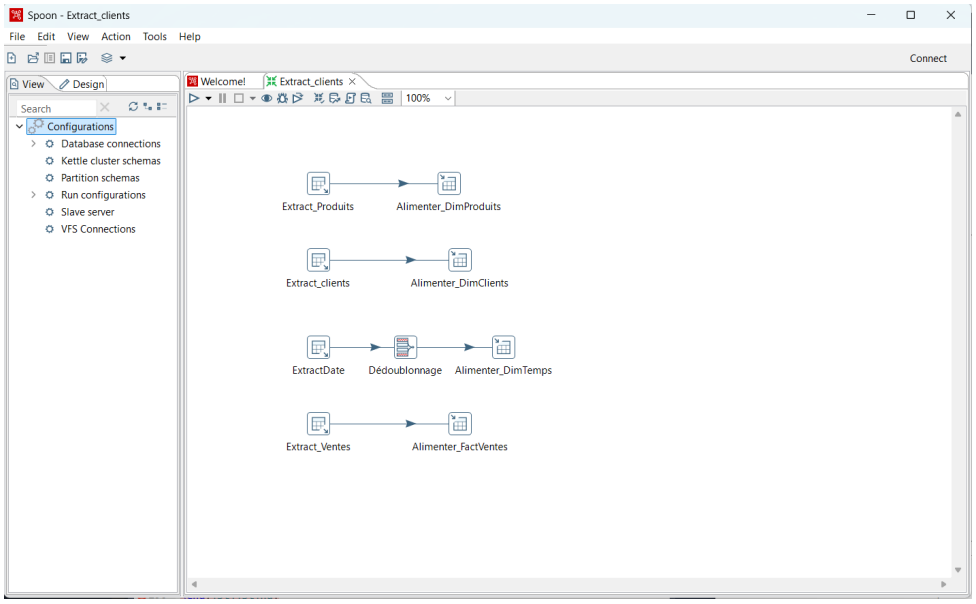

FIGURE 4.1 – Transformation Générale

4.2 Dimension Produits

4.2.1 Extraction

[language=SQL, basicstyle=] `SELECT p.Rf`$produit, p.Nom_produit, c.Nom_categorieFROMprod.produits$
$c.Code_categorie$

4.2.2 Chargement

Mapping des champs :

Table	Flux
idProd	Rf$_produit$
NomProd	Nom$_produit$
CatProd	Nom$_categorie$

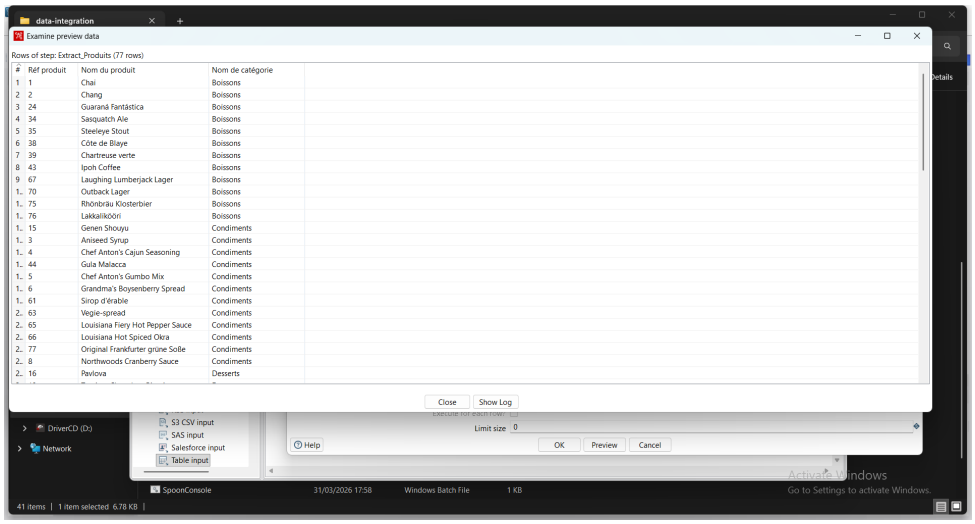

FIGURE 4.2 – Prévisualisation des produits extractés

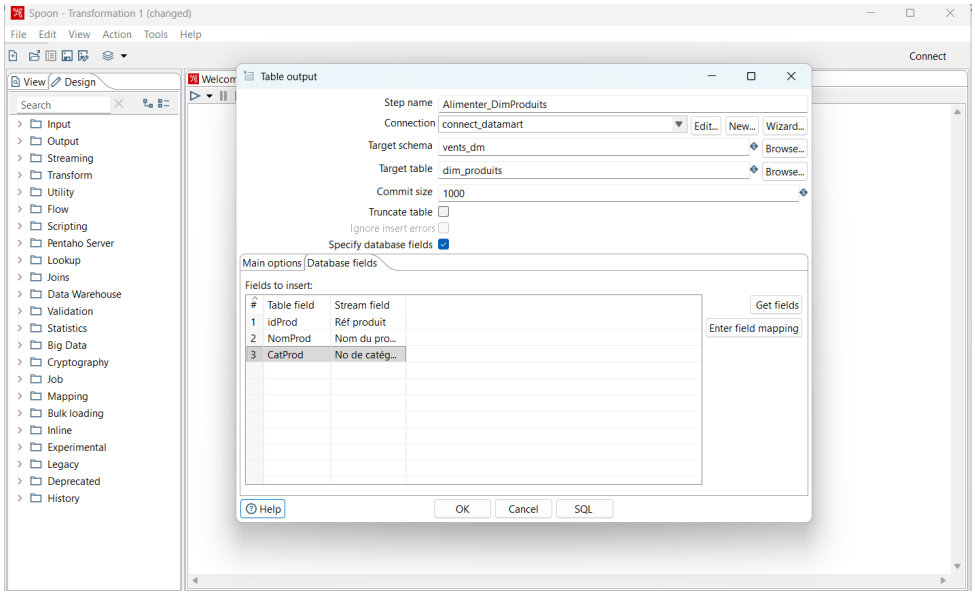

FIGURE 4.3 – Chargement des produits

4.3 Dimension Clients

Requête d'extraction : [language=SQL] SELECT c.Code$_client, c.Societe, c.PaysFROMprod.clients$

4.4 Dimension Temps

4.4.1 Extraction et Transformation

[language=SQL] SELECT c.Date$_{c}ommande, MONTH(c.Date_{c}ommande)FROMprod.commandes$
Transformation : Déduplication sur date et mois pour éviter les doublons.

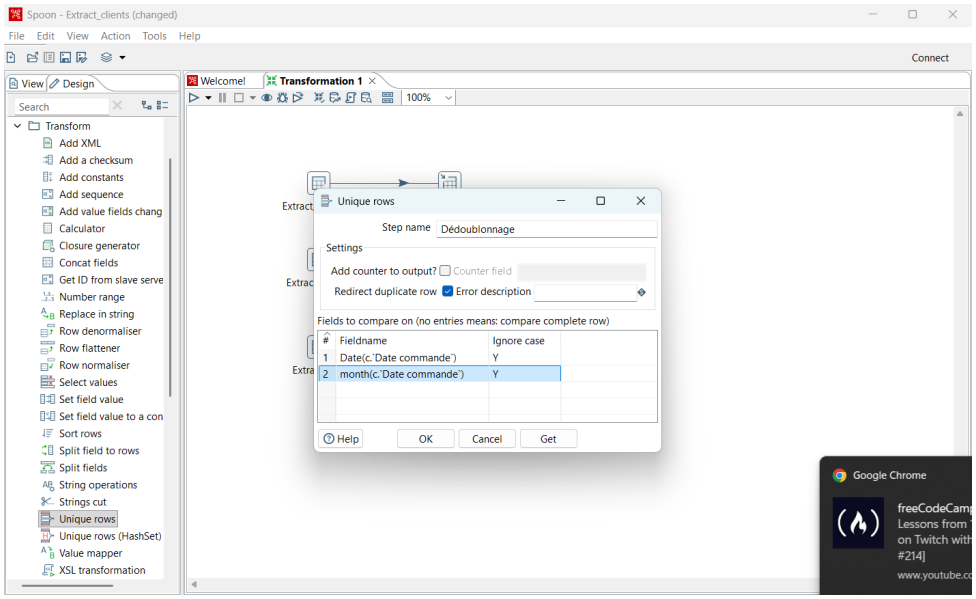

FIGURE 4.4 – Déduplication sur date et mois

4.5 Faits Ventes (Agrégation)

Requête agrégée complexe : [language=SQL, basicstyle=] `SELECT SUM(d.Quantite), SUM(d.Quantite * p.prixunitaire), c.Date`$_{c}ommande, p.Rf_{p}roduit, clt.Code_{c}lientFROMprod.DetailsCmdd, prod.produitsp, prod.commandesc, prod.clientscltWHEREclt.Code_{c}l$
$c.Code_{c}lientANDc.N_{c}ommande = d.N_{c}ommandeANDp.Rf_{p}roduit = d.Rf_{p}roduitGROUPBYc.Date_{c}ommande, p.Rf_{p}roduit, clt.Code_{c}lient$

Chapitre 5

Vérification et Validation

5.1 Contrôle des Données

Vérification dans MySQL Workbench :

- `DimClients` : 20+ clients (ALFKI-Allemagne, ANATR-Mexique...)
- `DimProduits` : 77 produits (Chai-Boissons, Aniseed-Condiments...)
- `DimTemps` : Dates janvier 2000 (Mois=1)
- `FactVentes` : Mesures Quantité/Montant par client/produit/jour

5.2 Exemples de Données Chargées

```
-- DimClients
ALFKI | Alfreds Futterkiste | Allemagne
ANATR | Ana Trujillo...     | Mexique

-- FactVentes
Quantite | Montant | idCl | idProd | idJours
1        | 180     | ANATR| 69    | 2000-10-19
```

5.3 Tests d'Intégrité

Toutes les contraintes de clés étrangères respectées. Cohérence des agrégations vérifiée.

Chapitre 6

Conclusion et Perspectives

6.1 Bilan du Projet

Le Data Mart `ventesDM` est opérationnel et prêt pour :

- Analyses temporelles (ventes par jour/mois)
- Analyses par catégorie produit
- Analyses par pays client
- Tableaux de bord BI futurs